

UNIVERSIDAD COMPLUTENSE DE MADRID

Máster en Big Data, Data Science &
Inteligencia Artificial

Trabajo fin de máster



Fenotipado digital basado en VOCs

Para modelar la interacción
planta-microorganismo y la
resiliencia vegetal
mediante aprendizaje
automático

Autora: Bolatti, Sofia Huilén

Tutores: Mota, Santiago y
Ortega, Carlos

2026





Índice

Resumen ejecutivo.....	2
Introducción y contexto.....	2
Objetivos y alcance.....	3
Los datos: qué usamos y por qué.....	4
La arquitectura del proyecto.....	6
El camino recorrido: decisiones clave.....	6
Qué tan bien predice el modelo.....	9
Qué compuestos importan y por qué.....	10
Mapear el espacio de estados posibles.....	11
Generación de hipótesis para validar en laboratorio.....	13
Herramientas y arquitectura técnica.....	14
De los modelos a una herramienta usable: el dashboard.....	15
Aplicaciones y valor práctico.....	16
Limitaciones.....	17
Conclusiones y próximos pasos.....	18
Vinculación con el temario del máster.....	18
Anexos.....	19
Bibliografía.....	19



Resumen ejecutivo

Las plantas no se quedan calladas frente a lo que les pasa. Emiten al aire una mezcla de compuestos químicos volátiles (VOCs) que cambia según su estado, ya sea que estén sanas, bajo ataque de un patógeno o protegidas por un microorganismo benéfico. Este trabajo indaga si esa "huella química" contiene información suficiente para diagnosticar automáticamente el estado de una planta, y si es posible ir un paso más allá del diagnóstico e imaginar computacionalmente qué compuestos cambiarían si esa planta transicionara hacia un estado de mayor resiliencia.

Para responder esa pregunta se construyó, a partir de siete estudios públicos disponibles, una base de datos curada de perfiles VOC en seis especies vegetales, sobre la cual se entrenaron tres capas de modelos que se apoyan una en la otra. La primera es un clasificador que diagnostica el estado fisiológico de una planta a partir de su perfil químico, con una precisión que varía según cuántos datos hay disponibles por especie. La segunda es un modelo generativo que aprende a "imaginar" cómo cambiaría ese perfil si la planta pasara de un estado a otro, señalando qué compuestos están más asociados a esa transición. La tercera es un control de plausibilidad química que evalúa si esos perfiles imaginados son creíbles o simplemente inventados sin sentido. En las cuatro especies con datos suficientes para esta prueba, el 100% de los 154 perfiles generados y evaluados resultó químicamente plausible, incluso al extrapolar más allá de lo observado.

El resultado no se queda en una validación estadística abstracta. Varios de los compuestos que los compuestos que el clasificador y el modelo generativo señalan como relevantes coinciden con marcadores de defensa vegetal ya documentados en la literatura científica, entre ellos delta-Cadinene en vid (clasificador) y metil salicilato en pimiento (modelo generativo), una molécula central en la respuesta de defensa sistémica de las plantas, lo que respalda los hallazgos. Lo que queda, entonces, es un conjunto de firmas volátiles candidatas, priorizadas por plausibilidad y listas para una futura validación experimental, acompañado de un pipeline reproducible y de un panel interactivo que permite explorar estos resultados sin necesidad de programar.

Introducción y contexto

Las plantas no son organismos silenciosos. Emiten constantemente al aire una mezcla de compuestos orgánicos volátiles (VOCs) que funciona como una forma de comunicación con su entorno, y que cambia según lo que les está pasando, si están sanas, si están bajo ataque de un patógeno, si un insecto se las está comiendo, o si están protegidas por un microorganismo aliado. Eso convierte a los VOCs en una especie de huella digital química del estado fisiológico de la planta, medible sin necesidad de dañarla ni de esperar a que aparezcan síntomas visibles.

Esa capacidad tiene una aplicación práctica directa. Si se puede leer esa huella con suficiente precisión, se abre la puerta a diagnósticos tempranos de estrés vegetal y a identificar qué compuestos están asociados a una mejor respuesta frente a patógenos o plagas, algo valioso tanto para la investigación en fisiología vegetal como para la agricultura de precisión. El interés original de este trabajo estaba puesto específicamente en la interacción entre plantas y *Trichoderma*, un género de hongos beneficiosos



ampliamente usado como bioprotector agrícola, pero la disponibilidad real de datos públicos con réplicas individuales llevó a ampliar el enfoque. En lugar de limitarse a una sola interacción planta-microorganismo, el trabajo terminó cubriendo seis especies vegetales y siete estudios distintos, con una variedad de estados fisiológicos contrastantes (control sano, infección por patógenos, herbivoría, protección por microorganismos benéficos) que comparten la misma pregunta de fondo. Esa ampliación no diluyó el foco original, sino que lo puso a prueba con un conjunto de evidencia mucho más amplio.

La pregunta que guía este trabajo es si es posible aprender, a partir de perfiles de VOCs, una representación que permita tanto diagnosticar el estado fisiológico de una planta como explorar computacionalmente qué compuestos cambiarían si esa planta transicionara hacia un estado más favorable. Este trabajo pone a prueba tres apuestas concretas detrás de esa pregunta. La primera es que los perfiles de VOCs contienen información suficiente para distinguir entre estados fisiológicos. La segunda, que esa información puede organizarse en un espacio interno con sentido biológico y no solo estadístico. La tercera, que a partir de ese espacio es posible generar perfiles químicos plausibles (químicamente creíbles) asociados a estados de mayor resiliencia, que sirvan como punto de partida para investigación futura en laboratorio.

Frente al estado del arte en volatilómica computacional, esta combinación (un modelo generativo condicional junto con un control de plausibilidad basado en detección de anomalías, aplicados a perfiles de compuestos orgánicos volátiles de origen vegetal) no tiene precedentes documentados en la literatura revisada para este trabajo. La mayoría de los estudios publicados en este campo se detienen en la clasificación supervisada de estados fisiológicos a partir de VOCs, que equivale apenas a la primera de las tres capas de este proyecto, sin explorar computacionalmente qué compuestos caracterizarían transiciones hacia estados todavía no observados. Este trabajo, entonces, no se limita a aplicar aprendizaje automático a un problema biológico ya estudiado, sino que extiende el tipo de pregunta que estas técnicas permiten responder en este dominio.

Objetivos y alcance

El objetivo general de este trabajo es desarrollar un marco computacional que use los perfiles de VOCs como un "fenotipo digital", capaz de caracterizar el estado fisiológico de una planta y de explorar, mediante un modelo generativo, qué firmas químicas están asociadas a estados de mayor resiliencia frente a estrés biótico.

Para llegar a ese objetivo general, el trabajo se organizó en torno a seis objetivos específicos, detallados en la siguiente tabla.

Objetivo	En qué consiste
Curar una base de datos	Integrar datos públicos de seis especies vegetales y siete estudios, estandarizando la identidad química de los compuestos y unificando los metadatos biológicos
Diagnosticar el estado fisiológico	Entrenar un modelo de clasificación por especie que, a partir del perfil químico, prediga si la planta está sana,

	infectada, bajo herbivoría o protegida por un microorganismo
Explicar qué compuestos importan	Identificar, para cada modelo, qué compuestos son más determinantes en el diagnóstico
Explorar transiciones entre estados	Construir un modelo generativo que, dado un estado de partida, imagine el perfil químico correspondiente a otro estado, señalando qué compuestos cambian
Evaluar la plausibilidad de lo generado	Determinar si los perfiles imaginados por el modelo generativo son químicamente creíbles o si carecen de sentido biológico
Productivizar el modelo	Construir un panel interactivo para explorar los datos, las predicciones y las hipótesis generadas

Este trabajo se presenta bajo la **Opción 3** de la guía del TFM, dado que integra la curación de siete estudios públicos distintos, un modelo generativo condicional y un control de plausibilidad además de la clasificación supervisada, y una capa de productivización con reentrenamiento validado por humano.

Los datos: qué usamos y por qué

Los datos de este trabajo provienen enteramente de estudios científicos publicados, con sus datos crudos disponibles públicamente o cedidos directamente por los autores. Se priorizaron datasets con réplicas biológicas individuales, porque un promedio no permite entrenar ni evaluar un modelo de aprendizaje automático de forma clara, y también se exigió que la técnica de medición fuera comparable entre estudios (GC-MS o SPME-GC-MS) y que las condiciones experimentales estuvieran claramente etiquetadas. Se revisaron en profundidad los repositorios públicos más relevantes del área, entre ellos MetaboLights, GNPS, Zenodo y Dryad, y en los casos donde el repositorio público no incluía las réplicas individuales, se contactó directamente a los autores del estudio, lo que permitió recuperar datos que de otra forma no habrían sido utilizables.

Con ese criterio, el trabajo quedó conformado por seis especies vegetales y siete estudios. Uno de ellos, al combinar tomate y pimiento, se trató como dos conjuntos independientes porque no comparten ningún compuesto químico medido en común.

Especie	Estudio	Interacción biológica	Compuestos /muestras
Vid (<i>Vitis vinifera</i>)	Lazazzara 2018	Infección por <i>Plasmopara viticola</i>	51/98
Cebada (<i>Hordeum vulgare</i>)	Laupheimer 2024	Oídio (<i>Blumeria hordei</i>)	25/32
Tomate (<i>Solanum lycopersicum</i>)	Alinç 2026	Hongo benéfico <i>T. harzianum</i> T22 + herbivoría	23/15



Tomate (<i>Solanum lycopersicum</i>)	Ghosh 2022	Virus TYLCV	76/15
Pimiento (<i>Capsicum annuum</i>)	Ghosh 2022	Virus PeWBVYV	93/14
Colza silvestre (<i>Brassica rapa</i>)	Moreira 2024	VOCs florales, herbivoría + patógenos	15/60
Algodón (<i>Gossypium hirsutum</i>)	Ayelo 2026	Resistencia de cultivar + herbivoría	13/60

Antes de poder usarse, estos datos pasaron por un proceso de curación. La identidad química de cada compuesto se resolvió contra PubChem, un identificador numérico único conocido como CID, porque un mismo compuesto puede aparecer con nombres distintos entre publicaciones. Toda la información quedó organizada en una base de datos estructurada, con los metadatos de muestras y compuestos en SQLite y las matrices de abundancia en formato Parquet, de manera que los mismos datos pudieran alimentar, sin duplicar trabajo, tanto el clasificador como el modelo generativo y el dashboard.

Antes de entrenar cualquier modelo, se realizó un análisis exploratorio por especie, visualizando los cinco compuestos con mayor variación entre estados fisiológicos y cómo se distribuye su abundancia en cada grupo. Este paso permite detectar a simple vista si existen diferencias de abundancia entre estados, y fue precisamente en esta etapa exploratoria donde se identificó por primera vez la señal anómala del ftalato de dibutilo en los datos de vid, confirmada como contaminación de laboratorio y corregida antes del modelado.

Este trabajo tiene una limitación, tres de los siete conjuntos (los dos estudios de Ghosh et al., 2022, y el de Alınç et al., 2026) tienen una cantidad de compuestos medidos alta en relación con la cantidad de muestras disponibles. Esto no es un error de curación sino una restricción real de los datos de origen, ya que son los únicos estudios públicos encontrados para esas interacciones biológicas con réplicas individuales disponibles. En vez de descartarlos, se decidió mantenerlos en el proyecto, pero tratarlos como resultados descriptivos y cualitativos en las etapas de modelado, no como resultados con la misma confianza estadística que las cuatro especies con más datos (vid, cebada, colza y algodón). Esta distinción se mantiene de forma consistente en todo el documento.

Detalle técnico. La base de datos se organiza en tres tablas relacionadas, siguiendo un diseño normalizado estándar. Una tabla de muestras (294 en total, con su especie, estado fisiológico y estudio de origen), una tabla de compuestos (297 compuestos catalogados entre los siete estudios, con su nombre original, número CAS cuando estaba disponible, e identificador PubChem), y una tabla de abundancias en formato largo que vincula cada muestra con cada compuesto medido y su valor de abundancia.

Este diseño evita repetir la información de un compuesto una vez por cada muestra que lo mide, y permite que las mismas tablas alimenten tanto el clasificador como el modelo generativo sin duplicar datos. Los metadatos se almacenan en SQLite, mientras que las matrices de abundancia se almacenan en formato Parquet, columnar y comprimido, más eficiente para ese uso.



La estandarización química, es decir, resolver cada compuesto contra un identificador único de PubChem, logró identificar 279 de los 297 compuestos catalogados, un 94%. Los 18 compuestos sin identificar se concentran mayormente en el estudio de vid (16 de 52 compuestos) y corresponden a picos cromatográficos sin coincidencia en las bases de referencia consultadas. Se mantienen en el análisis bajo un identificador interno, ya que descartarlos habría significado perder información real, aunque no se los pueda nombrar químicamente.

La arquitectura del proyecto

El proyecto se versiona en un repositorio Git, organizado en carpetas separadas por función, lo que permite ubicar cualquier pieza del trabajo sin recorrer todo el repositorio. La siguiente tabla resume qué contiene cada una.

Carpeta	Contenido
data/raw/	Datasets originales sin modificar, tal como fueron recibidos
db/	Base de datos SQLite con muestras y catálogo de compuestos, y matrices Parquet/CSV con las abundancias procesadas, vinculadas por sample_id
notebook/	Notebooks de exploración de datos, prototipado de modelos (clasificador, CVAE, Isolation Forest) y análisis de resultados
src/	Código fuente del pipeline, carga y limpieza de datos, construcción de la base SQLite/Parquet, y entrenamiento de modelos
models/	Artefactos ya entrenados por especie, clasificadores, CVAE, Isolation Forest o autoencoder, que el dashboard consume directamente sin reentrenar
dashboard/	Aplicación Flask y Plotly
docs/	Documentación del proyecto

Los datos crudos y procesados, así como la base de datos y las matrices Parquet, quedan explícitamente fuera del control de versiones, porque son regenerables en cualquier momento volviendo a correr los scripts de carga sobre los datos originales. Lo que se versiona es el proceso, no sus resultados binarios, lo que además mantiene liviano el repositorio.

El camino recorrido: decisiones clave

El primer enfoque que se probó para el clasificador de diagnóstico fue un único modelo entrenado con las seis especies juntas, que predecía una combinación de especie y estado fisiológico, nueve clases en total. Ese modelo se construyó, se entrenó, se evaluó y finalmente se descartó. La razón no fue un error técnico sino un hallazgo revelador, porque el modelo estaba aprendiendo a distinguir de qué estudio provenía cada muestra en lugar de aprender la biología real del estado fisiológico.



La respuesta a ese hallazgo fue rediseñar por completo el enfoque. En lugar de un modelo combinado, se construyó un modelo independiente por especie, siguiendo en cada caso el mismo proceso metodológico completo, que incluyó un árbol de decisión como referencia simple, Random Forest y XGBoost con búsqueda de hiperparámetros, comparación de modelos, y análisis de matriz de confusión e interpretabilidad. Esta decisión tiene un costo, ya que implica mantener siete modelos en vez de uno, y deja de lado la posibilidad de comparar directamente entre especies.

Este principio se puso a prueba de forma independiente y más exigente al construir la siguiente etapa del trabajo, el modelo generativo (CVAE). Al preparar el modelo para el estudio que mide conjuntamente tomate y pimienta (Ghosh et al., 2022), se encontró que ninguno de los 169 compuestos medidos en total es compartido entre ambas especies. 93 son exclusivos de pimienta y 76 de tomate. Combinarlos en un solo modelo no solo repetía el riesgo de efecto de lote ya identificado, sino que habría obligado a completar con ceros artificiales los compuestos que cada especie no comparte con la otra. Por eso este estudio se dividió también en dos modelos independientes, llevando el total de modelos generativos a siete para las seis especies del proyecto.

Que el mismo principio metodológico haya aparecido y se haya sostenido en dos etapas distintas del trabajo, con datos y técnicas diferentes, es la evidencia más sólida de que el diseño es una respuesta necesaria a cómo está estructurada la evidencia biológica disponible.

Detalle técnico. El preprocesamiento de las abundancias químicas incluyó dos pasos. El primero fue una transformación logarítmica para compensar la asimetría de las áreas de pico cromatográficas, que abarcan varios órdenes de magnitud entre compuestos. El segundo fue una estandarización por z-score sobre los valores ya transformados. Los valores no detectados (por debajo del umbral de detección del instrumento) se imputaron como cero antes de aplicar la transformación logarítmica. La partición entre entrenamiento y evaluación se realizó de forma estratificada por clase, reservando un 20% de las muestras para evaluación.

Para el clasificador de referencia se utilizó un árbol de decisión simple, limitado a una profundidad máxima de 5 niveles, como punto de partida antes de introducir modelos más complejos. Random Forest y XGBoost se ajustaron mediante búsqueda exhaustiva de hiperparámetros con validación cruzada de 5 particiones, optimizando el F1 macro promedio y ponderando las clases para compensar su desbalance. La siguiente tabla resume los valores explorados para cada hiperparámetro.

Modelo	Hiperparámetro	Valores explorados
Random Forest	Cantidad de árboles	50 a 200
	Profundidad máxima	5,10,20 niveles o sin límite
	Criterio de división	Gini o entropía
XGBoost	Cantidad de estimadores	50 a 150
	Tasa de aprendizaje	0.05 a 0.2
	Profundidad máxima	2 a 5 niveles

El modelo final para cada especie no se eligió únicamente por el mejor desempeño en validación cruzada. Entre las cinco mejores combinaciones de hiperparámetros, se priorizó la que mostrara menor diferencia entre el desempeño en entrenamiento y en evaluación, para reducir el riesgo de sobreajuste.

El modelo generativo (CVAE) se diseñó con un espacio latente de apenas dos dimensiones, dado el tamaño reducido de los datasets. El codificador combina el perfil químico de cada muestra con su condición fisiológica y lo procesa a través de dos capas densas (16 y 8 neuronas, con activación ReLU) antes de proyectarlo en los parámetros que definen la distribución del espacio latente. El decodificador realiza el camino inverso, es decir, a partir de un punto de ese espacio y una condición objetivo, reconstruye un perfil químico completo mediante dos capas densas simétricas a las del codificador. El entrenamiento combina dos objetivos. El primero es que la reconstrucción se parezca al dato original. El segundo, que el espacio latente mantenga una estructura regular. Ambos se equilibran mediante un esquema de calentamiento gradual a lo largo de las primeras 50 épocas, para evitar que el segundo objetivo domine antes de tiempo. El entrenamiento se extendió hasta 800 épocas, con el tamaño de las capas ajustado a la baja en los datasets más chicos para evitar que el modelo memorice en lugar de aprender un patrón general. La siguiente tabla muestra el tamaño real del codificador usado en cada uno de los siete modelos, y permite ver concretamente ese ajuste. El diseño condicional del modelo, es decir, que tanto el codificador como el decodificador reciban explícitamente el estado fisiológico como variable adicional, no forma parte del temario cursado en la maestría, que cubre autoencoders y el autoencoder variacional pero no su variante condicional, así que se incorporó de manera autodidacta siguiendo el modelo CVAE original (Sohn et al., 2015).

Especie / estudio	Compuestos / muestras	Capas del codificador
Vid (Lazazzara)	51/98	16 → 8 neuronas
Cebada (Laupheimer)	25/32	16 → 8 neuronas
Colza silvestre (Moreira)	15/60	16 → 8 neuronas
Algodón (Ayelo)	13/60	16 → 8 neuronas
Tomate (Alinç)	23/15	8 → 4 neuronas
Tomate (Ghosh)	76/15	4 neuronas (una sola capa)
Pimiento (Ghosh)	93/14	4 neuronas (una sola capa)

El patrón es consistente con el criterio metodológico. Los tres modelos entrenados con menos de 20 muestras (Alinç y los dos de Ghosh) son también los que usan la arquitectura más chica, lo que reduce el riesgo de que una red con más parámetros que muestras termine memorizando en lugar de generalizar.

Detalle técnico — hiperparámetros finales de los modelos ajustados. De las seis especies con clasificador, dos usan un modelo ajustado por búsqueda de hiperparámetros en lugar del árbol de decisión simple. Para **algodón** (Ayelo 2026), el modelo final es un **Random Forest** con criterio de división Gini, profundidad máxima de 5 niveles, mínimo de 3 muestras por hoja, mínimo de 5 muestras para dividir un nodo, y 200 árboles. Para



el estudio combinado de **tomate y pimiento** (Ghosh 2022), el modelo final es un **XGBoost** con tasa de aprendizaje de 0.05, gamma de 0.1, profundidad máxima de apenas 2 niveles, y 150 estimadores.

En ambos casos, la profundidad reducida y la tasa de aprendizaje baja fueron parte de lo que permitió controlar el sobreajuste frente al conjunto de entrenamiento, que en ambos casos alcanza un F1 macro cercano a 1.0.

Detalle técnico — infraestructura de reproducibilidad. La reproducibilidad de los modelos entrenados dependió de fijar semillas aleatorias en cada etapa, en la partición de datos, en la inicialización de los algoritmos de scikit-learn, y en la inicialización de pesos de las redes neuronales.

Qué tan bien predice el modelo

El desempeño del clasificador varía sustancialmente entre especies, de 0.27 a 0.87 en F1 macro, y esa variación se explica mejor por el tipo de estrés biológico y el tamaño de cada estudio que por el algoritmo elegido. Ningún modelo (árbol de decisión, Random Forest o XGBoost) domina de forma consistente en todos los casos, y en la mayoría de las especies el modelo más simple, el árbol de decisión, resultó suficiente.

Especie	Estudio	Muestra	Nº de estados	Modelo seleccionado	F1 macro (test)
Vid	Lazazzara 2018	98	2	Árbol de decisión	0.80
Cabada	Laupheimer 2024	32	2	Árbol de decisión	0.53*
Colza	Moreira 2024	60	5	Árbol de decisión	0.27*
Algodón	Ayelo 2026	60	2	Random Forest	0.87
Tomate + pimiento	Ghosh 2022	29	3	XGBoost	0.82
Tomate	Alinç 2026	15	3	(descriptivo)	(descriptivo)

*Resultados basados en conjuntos de evaluación muy pequeños (7 y 12 muestras); ninguna diferencia entre algoritmos en estos dos casos es estadísticamente sólida dado el tamaño de la muestra.

Dos aclaraciones son necesarias sobre esta tabla. La primera es que el caso de tomate y pimiento (Ghosh et al., 2022) se entrenó como un único modelo combinado, usando la especie como una variable más del modelo, una decisión distinta a la tomada más adelante para el modelo generativo, donde ambas especies se separaron por no compartir compuestos medidos en común. Esto es porque clasificar y generar son tareas distintas, y lo que resuelve bien una no necesariamente resuelve bien la otra. La segunda aclaración es que el caso de tomate con *Trichoderma* (Alinç 2026) se trató de forma puramente descriptiva, sin dividir entre entrenamiento y evaluación. Con apenas 15 muestras, cualquier partición habría dado una métrica de precisión aparente pero

poco confiable, y la práctica de dividir datos tan chicos no forma parte de la metodología de referencia seguida en este trabajo.

Más allá de las métricas, dos hallazgos biológicos transversales respaldan que el pipeline está capturando señal real y no ruido. El primero es que el **linalool** resultó relevante en 3 de los 6 análisis (vid, cebada, colza), lo que lo convierte en candidato a marcador general de estrés biótico. El segundo es que, en algodón, los compuestos más determinantes (**DMNT y beta-ocimeno**) son señales de defensa indirecta extremadamente bien documentadas en la literatura de herbivoría vegetal.

Detalle técnico.

Especie	Modelo Final	Precisión/Sensibilidad/F1 por clase (evaluación)
Vid	Árbol de decisión	Control: 0.75 / 0.90 / 0.82 (10 muestras); Infectada: 0.88 / 0.70 / 0.78 (10 muestras)
Cebada	Árbol de decisión	Control: 0.60 / 0.75 / 0.67 (4 muestras); Infectada: 0.50 / 0.33 / 0.40 (3 muestras)
Colza	Árbol de decisión (mas profundidad)	Control: 0.33 / 0.50 / 0.40 (2); Herbivoría por pulgón: 0.00 / 0.00 / 0.00 (2); Herbivoría por oruga: 1.00 / 0.33 / 0.50 (3); Infección bacteriana: 0.33 / 0.67 / 0.44 (3); Infección fúngica: 0.00 / 0.00 / 0.00 (2)
Algodón	Random Forest	Control: 0.67 / 1.00 / 0.80 (2); Expuesta a herbivoría: 1.00 / 0.90 / 0.95 (10)
Tomate + Pimiento	XGBoost	Control: 0.67 / 1.00 / 0.80 (2); Herbivoría: 1.00 / 0.50 / 0.67 (2); Infección viral: 1.00 / 1.00 / 1.00 (2)

Para el estudio de tomate y pimiento se compararon los tres algoritmos antes de elegir uno. El árbol de decisión alcanzó un F1 de 0.91 en entrenamiento pero cayó a 0.41 en evaluación. Random Forest mostró el mismo patrón, con F1 perfecto en entrenamiento y apenas 0.40 en evaluación. XGBoost, en cambio, mantuvo un F1 de 0.82 en evaluación pese a también ajustar perfectamente en entrenamiento, y se lo eligió precisamente por esa menor brecha entre entrenamiento y evaluación, señal de que generaliza mejor y no solo memoriza. Vale aclarar, para la lectura de la tabla, que en colza dos de las cinco clases (herbivoría por pulgón e infección fúngica) obtienen F1 de cero, pero con apenas 2 muestras de evaluación por clase esto refleja el tamaño de la muestra y no una falla del modelo.

Sobre las métricas usadas. La precisión de una clase mide, de todas las muestras que el modelo asignó a esa clase, qué proporción realmente pertenecía a ella. La sensibilidad, o recall, mide, de todas las muestras que realmente pertenecían a esa clase, qué proporción el modelo logró identificar. El F1 es la media armónica entre ambas, y penaliza con más fuerza que un promedio simple cualquier desbalance marcado entre precisión y sensibilidad. El F1 macro, la métrica usada para comparar modelos en este trabajo, promedia el F1 de cada clase sin ponderar por su cantidad de muestras, a diferencia del F1 ponderado. En datasets con clases desbalanceadas, un F1 ponderado puede cubrir un mal desempeño en la clase minoritaria, que suele ser justamente el estado fisiológico menos representado y más relevante de detectar.

Qué compuestos importan y por qué

Más allá de qué tan bien predice cada modelo, vale la pena mirar qué compuestos específicos usó cada uno para decidir, porque ahí es donde se puede evaluar si el modelo aprendió biología real o solo detectó patrones estadísticos sin sentido. En la mayoría de las especies, los compuestos señalados como más determinantes tienen respaldo directo en la literatura de defensa vegetal, lo que da confianza en que el pipeline está capturando señal biológica real.

En **vid**, los tres compuestos más relevantes para el clasificador (delta-Cadinene, Linalool y beta-Cariofileno) son sesquiterpenos y monoterpenos típicamente asociados a la respuesta de defensa de la planta frente a patógenos, consistentes con el tipo de estudio de origen, la infección por *Plasmopara viticola*.

En **algodón**, el trío formado por (Z)-3-Hexenyl acetate, DMNT y beta-Ocimeno son compuestos inducidos por herbivoría, conocidos como HIPVs, y están entre los marcadores más citados en ecología química vegetal para señalar daños por insectos, lo cual es coherente con el diseño del estudio de origen. En el estudio combinado de **tomate** y **pimiento**, los compuestos más relevantes, guaiacol y benzaldehído, son compuestos fenólicos y aromáticos vinculados a respuesta de estrés, consistentes con una infección viral.

En **cebada**, el linalool aparece como marcador, aunque el conjunto de evaluación fue de apenas 7 muestras, por lo que se reporta como tentativo. En **colza**, los dos compuestos señalados, 6-Methyl-5-hepten-2-one y (E)-beta-farneseno (este último es la feromona de alarma de los pulgones, reutilizada por la planta como señal de defensa), solo mostraron señal clara en 3 de las 5 clases del estudio, no en todas. En el caso de **tomate** con *Trichoderma*, la muestra es tan chica que no se llegó a marcadores concluyentes, más allá de una tendencia general en terpenos.

Un patrón transversal cierra esta sección. El **linalool** aparece como relevante en 3 de las 6 especies analizadas (vid, cebada, colza), lo que lo convierte en el candidato más fuerte del proyecto a marcador general de estrés biótico, presente más allá de una sola especie o un solo tipo de patógeno.

Detalle técnico — SHAP. El diseño condicional del modelo, es decir, que tanto el codificador como el decodificador reciban explícitamente el estado fisiológico como variable adicional, no forma parte del temario cursado en la maestría, que cubre autoencoders y el autoencoder variacional pero no su variante condicional, así que se incorporó de manera autodidacta siguiendo el modelo CVAE original (Sohn et al., 2015).

Calcular esto de forma exacta sería inviable con más de una decena de variables, pero para modelos basados en árboles, existe el algoritmo TreeExplainer que aprovecha la estructura del árbol para obtener el mismo resultado sin fuerza. La importancia reportada en este trabajo es el promedio del valor absoluto de esa contribución sobre el conjunto de evaluación, y en los estudios con más de dos estados fisiológicos posibles se promedia además entre clases. Esto prioriza un ranking general de qué compuestos pesan más en el diagnóstico, por sobre el detalle de cómo influye cada uno en cada clase específica.

Mapear el espacio de estados posibles

Además de diagnosticar, se construyó un modelo generativo, un Autoencoder Variacional Condicional o CVAE, para cada especie, siete modelos en total, ya que el estudio que combina tomate y pimiento requirió dos modelos independientes en lugar de uno por no compartir compuestos medidos. En lugar de responder "¿en qué estado está la planta?", este modelo permite preguntar algo distinto, "si esta planta pasara de un estado a otro, ¿qué compuestos cambiarían?". Es una herramienta de exploración, no de diagnóstico.

Antes de leer los resultados hace falta una aclaración importante. El modelo recibe el estado fisiológico de cada muestra de forma explícita durante el entrenamiento, así que no necesita usar su mapa interno para diferenciar entre estados. Por eso el indicador de separación del mapa, el silhouette score, se reporta con cautela. Lo que realmente importa es qué compuestos señala el modelo como más asociados a cada transición.

Especie	Silhouette	Qué señala la exploración
Vid	0.11	Mezcla heterogénea de volátiles (2-pentilfurano, benzenacetaldehído, beta-mirceno), sin un compuesto dominante único
Cebada	0.26	Fuerte desplazamiento de monoterpenos: linalool, mentol, canfor, 1,8-cineol, canfeno
Tomate (Alinc)	-0.18	Desplazamiento amplio de terpenos (alfa-terpineno, alfa-tuyeno, humuleno, beta-elemeno), familia consistente con respuesta general a herbivoría, sin un único marcador destacado
Tomate (Ghosh)	0.00	Señal mixta y débil (hexanal, guaiacol, alfa-pineno), peor ajuste del modelo
Pimiento (Ghosh)	0.02	Predominan ésteres metílicos de ácidos grasos (palmitato, laurato, palmitoleato). Metil salicilato destaca en la comparación con infección viral
Colza	-0.30	Supresión de varios compuestos florales en herbivoría e infección fúngica; la infección bacteriana es la única condición donde el patrón se invierte, con benzaldehído como diferenciador
Algodón	-0.22	Familia de compuestos inducidos por herbivoría (HIPVs): alfa-humuleno, (Z)-3-hexenil acetato, beta-ocimeno, beta-cariofileno

El patrón más claro y consistente aparece en colza, donde la infección bacteriana es la única de las cuatro condiciones de estrés en la que el modelo señala inducción de compuestos en lugar de supresión, con el benzaldehído como el diferenciador más marcado. En el resto de las especies, la exploración tiende a señalar familias químicas completas (terpenos, ésteres grasos, HIPVs) más que un único compuesto, lo cual es en sí mismo un resultado, ya que la respuesta química de una planta a estrés rara vez pasa por un solo compuesto, y el modelo lo refleja.



Detalle técnico. El espacio latente se visualiza proyectando en dos dimensiones el punto medio de la distribución que el codificador aprende para cada muestra de evaluación. El silhouette score se calcula sobre esa proyección usando el estado fisiológico como etiqueta de referencia, exclusivamente a fines diagnósticos, ya que separar esos estados no es un objetivo que el modelo persiga durante el entrenamiento. La exploración por gradiente parte de un punto fijo del espacio latente e interpola la condición fisiológica entre el estado control y el estado objetivo en once pasos sucesivos, decodificando cada paso para obtener un perfil químico completo. La extrapolación repite el mismo procedimiento más allá del estado objetivo observado, para ver si el patrón se sostiene al proyectarlo más lejos de los datos reales.

Generación de hipótesis para validar en laboratorio

Que un perfil químico "imaginado" por el modelo generativo señale un compuesto interesante no alcanza. Antes hay que preguntarse si ese perfil es químicamente creíble o si carece de sentido. Para responder eso se usaron dos detectores de anomalías, Isolation Forest y un autoencoder de reconstrucción, entrenados desde cero solo con muestras reales, sin usar el propio modelo generativo como parte del criterio, porque evaluar un modelo con su propio criterio sería circular. Cada perfil generado se clasifica como plausible, frontera o novedoso según qué tan alejado esté de la distribución de muestras reales, exigiendo acuerdo entre ambos detectores para las categorías extremas.

Antes de confiar en el resultado de cada especie, se validó que ambos detectores realmente pudieran distinguir un perfil deliberadamente falso, construido a propósito para esa prueba. Se encontró que la capacidad de estos detectores para descartar un perfil falso varía según el dataset, por eso ese control pasó a repetirse en cada especie por separado antes de confiar en sus resultados.

En cuatro especies (vid, cebada, colza y algodón) el control funcionó con confianza, lo que permitió evaluar cuantitativamente 154 perfiles generados por el modelo. El resultado es contundente. El 100% se clasifica como plausible, incluso los perfiles extrapolados más allá de la condición observada. En las tres especies restantes (tomate con *Trichoderma*, y tomate y pimiento del estudio de Ghosh) ni siquiera el perfil deliberadamente falso pudo distinguirse con confianza de uno típico, por lo que esos casos se reportan como cualitativos, sin forzar una clasificación que los datos no sostienen.

El resultado práctico de esta etapa es un conjunto de hipótesis priorizadas por plausibilidad. Colza vuelve a ser un buen ejemplo, ya que el control de plausibilidad confirmó que las 88 exploraciones evaluadas en esa especie son químicamente creíbles, incluyendo la que señala al benzaldehído como diferenciador entre infección bacteriana y fúngica.

Detalle técnico. El diseño condicional del modelo, es decir, que tanto el codificador como el decodificador reciban explícitamente el estado fisiológico como variable adicional, no forma parte del temario cursado en la maestría, que cubre autoencoders y



el autoencoder variacional pero no su variante condicional, así que se incorporó de manera autodidacta siguiendo el modelo CVAE original (Sohn et al., 2015).

Cada perfil generado se ubica dentro de esa distribución de referencia y se clasifica según en qué percentil cae. Por debajo del percentil 90 en ambos detectores se considera plausible. Entre el percentil 90 y 97.5, o si los dos detectores no coinciden, se considera frontera. Por encima del percentil 97.5 en ambos detectores se considera novedoso. Exigir que ambos detectores coincidan para las categorías extremas es una decisión conservadora.

Antes de confiar en estos resultados por especie, se corrieron dos pruebas de control independientes. La primera decodifica un punto muy alejado del centro del espacio latente, aunque esta prueba depende del propio decodificador del modelo generativo y puede dar una falsa sensación de robustez si el decodificador se satura. La segunda toma una muestra real y baraja al azar los valores de sus compuestos, rompiendo por completo la relación química entre ellos sin depender del modelo generativo. Esta segunda prueba resultó ser la más confiable para identificar las especies donde los detectores no tienen potencia estadística suficiente.

Por qué percentiles y no un test estadístico. El control de plausibilidad no usa un test estadístico paramétrico clásico, porque esos tests exigen supuestos sobre la forma de la distribución que son difíciles de sostener con 9 a 98 muestras por especie. En su lugar, se comparó directamente la posición de cada perfil generado dentro de la distribución empírica de scores observados en muestras reales, un enfoque no paramétrico, más robusto para datasets chicos, al costo de no producir un p-valor formal.

Herramientas y arquitectura técnica

Todo el proyecto está construido en Python, el lenguaje de referencia para ciencia de datos y aprendizaje automático, lo que permitió sostener una única base de código a lo largo de las cuatro etapas del trabajo, curación de datos, clasificación, modelado generativo y dashboard. La manipulación de datos se apoya en pandas y NumPy. Los modelos de clasificación, árbol de decisión y Random Forest, y el detector Isolation Forest usan scikit-learn, con XGBoost como librería específica para el gradient boosting. El modelo generativo (CVAE) y el autoencoder de detección de anomalías están implementados en TensorFlow y Keras, y la interpretabilidad de los clasificadores se apoya en la librería SHAP. Los datos se persisten en SQLite, para los metadatos relacionales, y en Parquet, para las matrices de abundancia, y el dashboard final está construido con Flask como framework web y Plotly para las visualizaciones interactivas. Esta combinación de herramientas, prioriza que el proyecto sea reproducible, auditable y extensible por otra persona.

Herramienta	Rol en el proyecto
Python	Lenguaje base de todo el pipeline
pandas / NumPy	Manipulación y transformación de datos
scikit-learn	Árbol de decisión, Random Forest, búsqueda de hiperparámetros, Isolation Forest



XGBoost	Clasificador de gradient boosting
TensorFlow / Keras	Modelo generativo (CVAE) y autoencoder de detección de anomalías
SHAP	Interpretabilidad de los clasificadores
SQLite	Metadatos relacionales (muestras, compuestos)
Parquet (PyArrow)	Matrices de abundancia química
Flask	Framework web del dashboard
Plotly	Visualizaciones interactivas del dashboard
Git	Control de versiones del código y de las decisiones del proyecto

Todo el desarrollo está versionado con Git desde el inicio del proyecto, lo que permite reconstruir la historia completa de decisiones técnicas, incluyendo los cambios de enfoque descritos en la sección anterior, como el abandono del clasificador combinado de nueve clases, y no solo su estado final. El repositorio sigue la misma organización por carpetas descrita antes, con los datos crudos y procesados fuera del control de versiones por ser voluminosos y regenerables. Esa disciplina fue justamente la que permitió, durante el proyecto, identificar con precisión en qué notebook se había introducido el problema de reproducibilidad del modelo generativo, y corregirlo con confianza sin perder el historial de resultados anteriores.

El dashboard, además de correr en el entorno local del proyecto, se publicó en Render, un servicio de despliegue en la nube que permite exponerlo con una URL pública para que los evaluadores lo revisen de forma independiente, sin depender de una demostración en vivo. Esta etapa de despliegue no forma parte del temario cursado en la maestría, que aborda la productivización de modelos con Bokeh Server y un stack de monitoreo con Prometheus y Grafana, así que se resolvió de manera autodidacta a partir de la documentación oficial de la plataforma (Render, 2026), con el dashboard disponible en <https://tfm-vocs-digital-phenotyping.onrender.com>. Al tratarse de una instancia gratuita, la primera carga tras un período de inactividad puede demorar hasta un minuto en activarse.

De los modelos a una herramienta usable: el dashboard

Todo lo descrito hasta acá, el clasificador, el modelo generativo, el control de plausibilidad, quedaría atrapado en notebooks si no hubiera una forma de que otra persona lo use sin programar. Por eso el proyecto se cierra con un panel interactivo, construido con Flask y Plotly, que consume directamente los modelos ya entrenados sin volver a entrenar nada al arrancar. Está organizado en seis módulos, pensados para recorrerse en el mismo orden en que se construyó el proyecto, desde explorar los datos crudos hasta actualizar un modelo con información nueva.

El primer módulo es **Exploración de datos (EDA)**, que muestra para cada especie los cinco compuestos con mayor variación entre estados fisiológicos, con sus nombres



depurados para que sean legibles por alguien sin formación química. El segundo es el **Predictor**, que aplica el clasificador de esa especie a una muestra ya existente en la base o a un archivo nuevo que el usuario suba, mostrando el diagnóstico, su nivel de confianza y la probabilidad asignada a cada estado posible, sin exigirle a quien lo usa que sepa qué hay detrás del modelo. El tercero es **SHAP**, que traduce la interpretabilidad técnica del clasificador en un gráfico simple de qué compuestos pesan más en esa predicción. El cuarto es el **Generador de hipótesis**, la puerta de entrada al modelo generativo, donde se elige una muestra real y un estado de destino, y el sistema devuelve el perfil químico imaginado para esa transición junto con una escala visual que indica, de un vistazo, si ese perfil resultó plausible, frontera o novedoso. El quinto es **Espacio latente**, que grafica el mapa interno del CVAE por especie, la vista más exploratoria de las seis. Y el sexto es el **Actualizador de modelo**, el módulo más orientado a uso productivo, que permite subir un CSV con datos nuevos, entrena un modelo candidato en paralelo sin tocar el que está en producción, compara su desempeño contra el modelo actual, y solo permite reemplazarlo si el candidato es mejor, con una confirmación explícita en un segundo paso.

Cada uno de estos módulos incluye, además, un selector de especie con nombres comunes junto al nombre científico (algodón, colza, cebada, vid, tomate, pimiento).

Este último módulo, el Actualizador de modelo, es en términos concretos la respuesta a lo que se entiende por "productivización". No es un modelo que se queda fijo, sino uno que puede seguir mejorando a medida que aparecen nuevos datos, sin arriesgar el modelo que ya está funcionando.

Detalle técnico. El dashboard está construido en Flask, con una separación clara entre las rutas de la aplicación y la lógica de acceso a datos. Un archivo concentra las seis rutas, una por módulo, y la generación de gráficos con Plotly, mientras que otro concentra toda la carga de modelos entrenados, consultas a la base de datos y cómputo de predicciones. Los modelos de clasificación se cargan desde archivos serializados en disco, y el codificador y decodificador del modelo generativo se cargan en su formato nativo. Ninguno se reentrena al iniciar la aplicación, por lo que levantar el dashboard es una operación liviana.

El módulo de actualización de modelo sigue un flujo de dos pasos, pensado deliberadamente para que ningún reemplazo sea automático. Al subir un CSV nuevo, el archivo se guarda con un identificador único generado para esa sesión, y se entrena un modelo candidato en paralelo, sin tocar el modelo en producción, devolviendo la comparación de desempeño contra el modelo actual. Solo si el usuario confirma explícitamente esa misma operación, usando el mismo identificador, el sistema reentrena sobre esos datos y sobrescribe los archivos del modelo guardado. Incluso en ese paso de confirmación, el sistema vuelve a verificar que el candidato efectivamente mejore antes de sobrescribir nada, como resguardo adicional.

Aplicaciones y valor práctico

Más allá de su valor como ejercicio metodológico, este trabajo tiene aplicaciones concretas en agricultura de precisión y protección vegetal. Un diagnóstico temprano del estado fisiológico de una planta a partir de su perfil de VOCs, sin necesidad de esperar



síntomas visibles ni de recurrir a análisis destructivos, es información directamente accionable para quien gestiona un cultivo, porque permite decidir cuándo y dónde aplicar un tratamiento en lugar de aplicarlo de forma preventiva y generalizada. Los principales beneficiarios de una herramienta de este tipo son equipos técnicos de empresas agrobiotecnológicas que desarrollan bioprotectores, como los basados en *Trichoderma*, el eje original de este trabajo, servicios de extensión agrícola que asesoran a productores, y grupos de investigación en fisiología vegetal que necesitan priorizar qué compuestos validar experimentalmente entre cientos de candidatos posibles.

La capa generativa del proyecto, el modelo CVAE junto con su control de plausibilidad, tiene un valor específico en el contexto de investigación y desarrollo. Identificar de antemano firmas químicas candidatas a marcador de resiliencia, priorizadas por su plausibilidad estadística, reduce el espacio de búsqueda antes de invertir en validación experimental de laboratorio, que es costosa en tiempo y en recursos. En lugar de medir decenas de compuestos en igualdad de condiciones, un equipo de investigación puede usar este tipo de herramienta para decidir por dónde empezar, como en el caso de la colza descrito antes, un ejemplo concreto del tipo de hipótesis priorizada y accionable que este enfoque puede producir de forma sistemática para cualquier especie con datos suficientes.

El dashboard, en este sentido, no es solo un accesorio de presentación, sino el vehículo que hace utilizable todo lo anterior por alguien sin formación en programación ni en aprendizaje automático. Un agrónomo o un investigador puede subir una muestra nueva, obtener un diagnóstico, entender qué compuestos lo explican, y explorar hipótesis generativas, todo sin escribir una línea de código. Esa accesibilidad, y no solo la precisión de los modelos, es lo que determina si un desarrollo de este tipo efectivamente se adopta fuera del contexto en el que fue construido.

Limitaciones

Este trabajo tiene límites reales, y conviene dejarlos explícitos en vez de disimularlos.

El más importante es el tamaño de los datos. Tres de los siete estudios (tomate con *Trichoderma*, y tomate y pimiento del estudio de Ghosh) tienen entre 9 y 15 muestras reales frente a decenas de compuestos medidos, una relación que limitó de forma consistente, en las tres etapas de modelado (clasificación, generación, plausibilidad), qué tan lejos se puede llegar con ellos. No son resultados descartables, pero se reportan con el nivel de confianza que les corresponde, descriptivos, no concluyentes. Incluso en dos de las cuatro especies con evaluación cuantitativa más sólida, cebada y colza, la métrica del clasificador baseline se apoya en conjuntos de evaluación de apenas 7 y 12 muestras, así que esas cifras puntuales deben leerse como una tendencia, no como un número definitivo.

El dataset ligado directamente al planteo original de esta tesis, la interacción con *Trichoderma*, es también el que menos señal concluyente aportó en las tres etapas de modelado, principalmente por su tamaño, y por eso vuelve a mencionarse.

Por último, dos limitaciones metodológicas más acotadas cierran esta sección. El mapa del espacio latente del CVAE se interpreta con cautela, ya que el modelo recibe el estado fisiológico de forma explícita y no necesita usar ese mapa para separar estados. Y los



resultados de los modelos generativos, al depender de la inicialización de pesos de una red neuronal, requieren fijar semillas de forma consistente para ser reproducibles.

Conclusiones y próximos pasos

La pregunta de partida era si los perfiles de VOCs contienen información suficiente para diagnosticar el estado fisiológico de una planta y para explorar, más allá del diagnóstico, qué compuestos están asociados a estados de mayor resiliencia. La respuesta, con la evidencia reunida en este trabajo, es afirmativa, aunque de forma desigual entre especies. El clasificador diagnostica con precisión aceptable a muy buena en cuatro de las seis especies analizadas, el modelo generativo logra representar transiciones entre estados con sentido químico reconocible en la mayoría de los casos, y el control de plausibilidad confirma que, en las especies con datos suficientes, prácticamente todo lo que el modelo genera es estadísticamente creíble, incluso al extrapolar más allá de lo observado.

De las tres apuestas planteadas al inicio, las primeras dos quedan respaldadas con evidencia sólida. Los perfiles de VOCs sí discriminan estados fisiológicos, y sí pueden organizarse en una representación con estructura biológica reconocible, aunque el mapa del espacio latente en sí deba interpretarse con cautela por el diseño condicional del modelo. La tercera, generar firmas volátiles plausibles asociadas a resiliencia, se cumple en un sentido estadístico y computacional, con un candidato especialmente concreto, el benzaldehído como diferenciador de infección bacteriana en colza, pero su validez biológica final solo la puede confirmar un experimento de laboratorio, no este trabajo.

De cara a una futura iteración, hay dos líneas de continuación claras. La primera, y la de mayor valor concreto, es ampliar específicamente el dataset de interacción con *Trichoderma*, el eje que dio origen a esta tesis y, como ya se señaló, el que menos señal concluyente aportó por su tamaño. La segunda, y la que cierra el ciclo que este trabajo dejó abierto, es la validación experimental en laboratorio de las firmas volátiles candidatas priorizadas por el control de plausibilidad, empezando por los casos con mejor respaldo estadístico.

El dashboard, en este sentido, no es un cierre sino una puerta. Su módulo de actualización de modelo está diseñado explícitamente para incorporar datos nuevos, de estas líneas de expansión o de cualquier otra fuente futura, sin necesidad de reescribir el pipeline, comparando cada modelo candidato contra el que está en producción antes de reemplazarlo. El objetivo de este trabajo nunca fue cerrar una pregunta, sino dejar una base sólida, reproducible y honesta sobre sus propios límites, para seguir haciéndola.

Vinculación con el temario del máster

Más allá de los módulos de Machine Learning y Deep Learning, que son el corazón técnico del proyecto, este trabajo integra contenidos de buena parte del resto del temario cursado, como muestra la siguiente tabla.



Módulo del máster	Aplicación concreta en este trabajo
Python y programación	Pipeline completo: carga, curación, modelado, dashboard
Bases de datos SQL	Diseño del esquema relacional (muestras, compuestos, abundancias) en SQLite
Fundamentos de estadística	F1 macro, silhouette score, calibración Leave-One-Out, umbrales por percentil
Minería de datos y modelización predictiva	Curación, estandarización, feature engineering por especie
Machine Learning	Random Forest, XGBoost, búsqueda de hiperparámetros, validación cruzada
IA con Deep Learning	Modelo generativo condicional (CVAE), autoencoder de detección de anomalías
Visualización avanzada	Gráficos interactivos del dashboard (Plotly)
Productivizar un modelo	Módulo de actualización de modelo del dashboard, con comparación y reemplazo controlado
GNU/Linux y Git	Repositorio versionado, con datos crudos y procesados excluidos del control de versiones y regenerables desde los scripts de carga

Anexos

Los anexos de este entregable incluyen el código fuente completo del proyecto, notebooks de curación, clasificación, modelado generativo y detección de anomalías, además del código del dashboard, organizado en el repositorio Git descrito en la sección "Herramientas y arquitectura técnica". Incluyen también las tablas de resultados completas por especie, matrices de confusión, métricas por clase, y la tabla completa de compuestos con su resolución PubChem, junto con los gráficos de importancia SHAP completos para las seis especies, que en el cuerpo de la memoria se resumen para mantener la lectura ágil. El acceso al código permite, además, reproducir cualquiera de los resultados reportados a partir de los datos originales, siguiendo el mismo proceso documentado en este trabajo.

Bibliografía

- Ayelo, P. M. et al. (2026). *Estudio de resistencia de cultivar de algodón (Gossypium hirsutum) frente a herbivoría por Spodoptera exigua*.
- Alınc, T. et al. (2026). *Interacción tripartita tomate–Trichoderma T22–Halyomorpha halys*.
- Ghosh, A. et al. (2022). *Perfiles VOC en tomate (TYLCV) y pimiento (PeWBVYV)*. Insects.
- Laupheimer, S. et al. (2024). *Volátiles de cebada frente a Blumeria hordei*. Physiologia Plantarum.
- Lazazzara, V. et al. (2018). *Volátiles de vid frente a Plasmopara viticola*.



Moreira, X. et al. (2024). *Efectos de herbivoría y patógenos sobre VOCs florales en Brassica rapa*. Journal of Ecology.

Render (2026). *Deploy a Flask App on Render*. Documentación oficial.

Sohn, K., Lee, H. y Yan, X. (2015). *Learning Structured Output Representation using Deep Conditional Generative Models*. Advances in Neural Information Processing Systems (NeurIPS).

Lundberg, S. M. y Lee, S.-I. (2017). *A Unified Approach to Interpreting Model Predictions*. Advances in Neural Information Processing Systems (NeurIPS).

Liu, F. T., Ting, K. M. y Zhou, Z.-H. (2008). *Isolation Forest*. 2008 Eighth IEEE International Conference on Data Mining, 413-422.